



UNIVERSIDAD PRIVADA DEL VALLE

FACULTAD: FACULTAD DE INFORMÁTICA Y ELECTRÓNICA

CARRERA: INGENIERÍA DE SISTEMAS INFORMÁTICOS

MATERIA: TECNOLOGÍAS EMERGENTES I

TI26 – Proyecto Final

Proyecto Final

MATERIA: Tecnologías Emergentes I

DOCENTE: Ing. Efrain Fernando Luna Mamani

ESTUDIANTE: Heredia Saravia Edwin

ILLANES CABALLERO JOEL ALEXANDER

FECHA PRESENTACIÓN INFORME: 17/06/2026

ÍNDICE

1. Introducción
2. Descripción del dataset
3. Análisis Exploratorio de Datos (EDA)
4. Preprocesamiento
5. Fundamentos teóricos del modelo principal (Random Forest / Bagging)
6. Base matemática y función objetivo
7. Proceso de entrenamiento
8. Hiperparámetros clave y su impacto
9. Ventajas, limitaciones y casos de uso reales
10. Implementación
11. Modelo comparativo (Support Vector Machine)
12. Resultados
13. Análisis e interpretación
14. Conclusiones
15. Referencias bibliográficas

1. INTRODUCCIÓN

1.1. Planteamiento del problema

En el entorno empresarial actual, la gestión de relaciones con clientes (CRM, por sus siglas en inglés Customer Relationship Management) constituye uno de los pilares fundamentales para el crecimiento comercial. Las empresas registran diariamente interacciones con clientes, actividades de venta y oportunidades de negocio que transitan por distintas etapas del embudo comercial: prospección, negociación, cierre exitoso (Won) o cierre fallido (Lost).

Predecir con anticipación si una oportunidad de venta será ganada o perdida permite a los equipos comerciales priorizar esfuerzos, asignar recursos de manera eficiente y diseñar estrategias personalizadas según el perfil del cliente, el producto ofrecido y el desempeño del agente de ventas. Sin embargo, el volumen de datos generados por un CRM dificulta el análisis manual de patrones, lo que hace necesario recurrir a técnicas de aprendizaje automático.

1.2. Objetivo del proyecto

El objetivo general de este trabajo — desarrollado en equipo por HEREDIA SARAVIA EDWIN e ILLANES CABALLERO JOEL ALEXANDER — es investigar, implementar y evaluar el algoritmo **Bagging: Random Forests** para clasificación binaria: predecir si una oportunidad CRM será **Won** o **Lost**, comparando su desempeño con **SVM** como modelo comparativo.

Los objetivos específicos son:

- a) Realizar un análisis exploratorio exhaustivo del dataset CRM Sales Opportunities, integrando las tablas de cuentas, productos, equipos de ventas y pipeline comercial.
- b) Aplicar técnicas de preprocesamiento: limpieza de nulos, unión de tablas, ingeniería de características temporales, encoding y partición train/test.
- c) Fundamentar teóricamente el algoritmo Random Forest y su función objetivo.
- d) Implementar y entrenar el modelo principal con hiperparámetros justificados.
- e) Implementar un modelo comparativo (SVM) bajo las mismas condiciones.
- f) Evaluar ambos modelos mediante accuracy, F1-score, matriz de confusión y curva ROC.
- g) Interpretar los resultados en el contexto de ventas y CRM, y proponer mejoras futuras.

1.3. Relevancia del problema

La predicción de cierre de oportunidades comerciales tiene impacto directo en la rentabilidad empresarial. Según la literatura de sales analytics, las organizaciones que adoptan modelos predictivos en su CRM logran incrementar tasas de conversión, reducir ciclos de venta y optimizar la asignación de leads a los agentes más adecuados.

Desde la perspectiva académica, este proyecto integra competencias de Tecnologías Emergentes I: integración de múltiples fuentes de datos, preprocesamiento de datos empresariales reales, comprensión de algoritmos de clasificación supervisada, evaluación rigurosa de modelos y comunicación técnica de resultados en la exposición del miércoles 17 de junio de 2026.

2. DESCRIPCIÓN DEL DATASET

2.1. Fuente y reserva

Nombre : CRM Sales Opportunities
Plataforma : Kaggle
Autor : innocentmfa
URL : <https://www.kaggle.com/datasets/innocentmfa/crm-sales-opportunities>
Licencia : Uso académico según términos de Kaggle
Reserva : Dataset reservado con el grupo vía WhatsApp para evitar duplicidad con compañeros.

2.2. Contexto del dataset

El dataset simula el sistema CRM de una empresa ficticia del sector hardware. Contiene información sobre cuentas de clientes (firmografía), catálogo de productos, equipos comerciales y el pipeline de oportunidades de venta con sus etapas, fechas y montos de cierre. Está diseñado para análisis de ventas,

visualización de datos y modelado predictivo.

2.3. Archivos y tablas

Archivo	Registros reales	Columnas	Descripción
sales_pipeline.csv	8 800	8	Oportunidades y etapas de venta
accounts.csv	85	7	Empresas clientes (firmografía)
products.csv	7	3	Catálogo de productos hardware
sales_teams.csv	35	3	Agentes, gerentes y oficinas
data_dictionary.csv	22 filas	3	Diccionario de campos (Table, Field, Description)

2.4. Variables por tabla

TABLA: sales_pipeline.csv

Variable	Tipo	Descripción
opportunity_id	Identificador	ID único de la oportunidad
sales_agent	Categórica	Agente de ventas responsable
product	Categórica	Producto ofertado
account	Categórica	Empresa cliente (puede ser nulo)
deal_stage	Categórica	Etapas: Prospecting, Engaging, Won, Lost
engage_date	Fecha	Fecha de inicio de negociación
close_date	Fecha	Fecha de cierre (Won/Lost)
close_value	Numérica	Monto del cierre en USD

TABLA: accounts.csv

account	Nombre de la empresa
sector	Sector industrial (categórica)
year_established	Año de fundación (numérica)
revenue	Ingresos anuales en millones USD (numérica)
employees	Número de empleados (numérica)
office_location	Ubicación de oficina principal (categórica)
subsidiary_of	Empresa matriz, si aplica (categórica)

TABLA: products.csv

product	Nombre del producto (categórica)
series	Línea de producto (categórica)
sales_price	Precio sugerido de venta en USD (numérica)

TABLA: sales_teams.csv

sales_agent | Nombre del agente (categórica)
manager | Gerente comercial (categórica)
regional_office | Oficina regional (categórica)

2.5. Dataset enriquecido para modelado

Para el modelado se unen las cuatro tablas principales mediante las claves:

- sales_pipeline.account → accounts.account
- sales_pipeline.product → products.product
- sales_pipeline.sales_agent → sales_teams.sales_agent

Resultado inmediato de la unión (notebook 01_EDA.ipynb, ejecutado):

Dataset enriquecido : 8 800 filas × 18 columnas
Nulos sales_price tras merge : 0

Columnas resultantes:

opportunity_id, sales_agent, product, account, deal_stage, engage_date,
close_date, close_value, sector, year_established, revenue, employees,
office_location, subsidiary_of, series, sales_price, manager, regional_office

Ejemplo de registro tras el merge (primeras filas del notebook):

opportunity_id : 1C1I7A6R
sales_agent : Moses Frase
product : GTX Plus Basic
account : Cancity
deal_stage : Won
engage_date : 2016-10-20
close_value : 1 054.0 USD
sector : retail
revenue : 718.62 (M USD)
employees : 2 448
sales_price : 1 096 USD
manager : Dustin Brinkmann
regional_office: Central

Tras filtrar solo oportunidades cerradas (deal_stage ∈ {Won, Lost}) para clasificación binaria, el dataset de modelado contiene:

Filas : 6 711 oportunidades cerradas
Columnas : 18 columnas originales + variable derivada won

Variable objetivo (target):

won = 1 si deal_stage == "Won" → 4 238 registros (63.15 %)

won = 0 si deal_stage == "Lost" → 2 473 registros (36.85 %)

2.6. Cumplimiento de requisitos del proyecto

Requisito	Cumplimiento
Mínimo 5 000 filas	Sí (~6 711 oportunidades cerradas)
Mínimo 13 columnas	Sí (17+ tras unión de tablas)
Al menos 3 variables categóricas	Sí (8+: sector, product, series, manager, regional_office, office_location, subsidiary_of, sales_agent)
Al menos 10 variables numéricas	Sí (10+: revenue, employees, sales_price, year_established, company_age, revenue_per_employee, engage_month, engage_quarter, engage_year, engage_dayofweek)
Requiere preprocesamiento	Sí (nulos, fechas, encoding, scaling)

2.7. Distribución de la variable objetivo

Entre las oportunidades cerradas (6 711 registros) se obtuvo la siguiente distribución al ejecutar el notebook 01_EDA.ipynb:

won = 1 (Won — oportunidad ganada) : 4 238 registros (63.15 %)
won = 0 (Lost — oportunidad perdida): 2 473 registros (36.85 %)
Total cerradas : 6 711 registros

Salida del notebook:

```
won
1  0.631501
0  0.368499
Name: proportion, dtype: float64
```

El desbalance es moderado, por lo que se reportará F1-score además de accuracy y se aplicará estratificación en la partición train/test.

2.8. Necesidad de preprocesamiento

- Valores nulos en account (~16 % del pipeline), engage_date (~6 %), close_date y close_value (~24 % en oportunidades aún abiertas).
- Fechas en formato texto que requieren conversión a datetime.
- Variables categóricas de alta y baja cardinalidad que requieren encoding.
- Escalas heterogéneas (revenue en millones vs. sales_price en unidades).
- Registros en etapas Prospecting y Engaging que deben excluirse del modelado binario Won/Lost.
- Unión de tablas con claves foráneas que puede generar registros sin match.
- Errores tipográficos en datos: sector "technolgy" (debería ser technology), office_location "Philippines" (debería ser Philipppines).

- subsidiary_of vacío en 70 de 85 cuentas (~82 %).
- Oportunidades Lost registran close_value = 0 en el 100 % de los casos.

2.9. Variables dependientes e independientes

El proyecto utiliza clasificación supervisada binaria sobre el dataset enriquecido (unión de las 4 tablas CSV).

VARIABLE DEPENDIENTE (Y):

won → Binaria (0 = Lost, 1 = Won), derivada de deal_stage

VARIABLES INDEPENDIENTES (X):

Catóricas (≥ 3): sector, product, series, sales_agent, manager, regional_office, office_location, subsidiary_of

Númericas (≥ 10): year_established, revenue, employees, sales_price, company_age, revenue_per_employee, engage_year, engage_month, engage_quarter, engage_dayofweek, has_subsidary, is_premium_product

Excluidas: opportunity_id, deal_stage, close_date, close_value, account

RELACIÓN ENTRE TABLAS:

sales_pipeline.account → accounts.account

sales_pipeline.product → products.product

sales_pipeline.sales_agent → sales_teams.sales_agent

3. ANÁLISIS EXPLORATORIO DE DATOS (EDA)

3.1. Metodología del EDA

El análisis exploratorio se realizó en el notebook 01_EDA.ipynb utilizando Python (pandas, NumPy, matplotlib, seaborn). Las etapas fueron:

1. Carga individual de las 4 tablas CSV.
2. Inspección de tipos, nulos y cardinalidad.
3. Unión de tablas (merge) para crear el dataset enriquecido.
4. Estadísticas descriptivas de variables numéricas y categóricas.
5. Análisis de la variable objetivo Won/Lost.
6. Visualizaciones de distribución, correlaciones y relaciones clave.

3.2. Inspección inicial de las tablas

Dimensiones al cargar (notebook 01_EDA.ipynb):

Pipeline : 8 800 filas × 8 columnas

Accounts : 85 filas × 7 columnas

Products : 7 filas × 3 columnas

Sales teams : 35 filas × 3 columnas

Valores nulos en sales_pipeline.csv:

account : 1 425 nulos (16.2 %)
engage_date : 500 nulos (5.7 %)
close_date : 2 089 nulos (23.7 %)
close_value : 2 089 nulos (23.7 %)

Distribución de deal_stage (conteo real):

Won : 4 238 oportunidades (48.2 %)
Lost : 2 473 oportunidades (28.1 %)
Engaging : 1 589 oportunidades (18.1 %)
Prospecting : 500 oportunidades (5.7 %)
TOTAL : 8 800

Observación: los 2 089 nulos en close_date y close_value coinciden exactamente con Engaging (1 589) + Prospecting (500). Los deals abiertos no tienen fecha ni monto de cierre. Los 1 425 account nulos corresponden a oportunidades abiertas; las 6 711 cerradas (Won/Lost) tienen account completo.

3.3. Dataset enriquecido (merge de tablas)

Tras merge_crm_tables() en el notebook 01:

Dimensiones : 8 800 filas × 18 columnas
Nulos en sales_price tras unión con products.csv : 0
(La corrección GTXPro → GTX Pro en paths.py evita pérdida de match)

3.4. Estadísticas descriptivas — oportunidades cerradas (n = 6 711)

Resultados obtenidos al ejecutar closed.describe() en 01_EDA.ipynb:

Variable	Media	Desv. est.	Mín.	Mediana	Máx.
close_value	1 490.92	2 320.67	0.0	472.0	30 288.0
revenue (M USD)	2 520.21	2 627.85	4.54	1 698.2	11 698.0
employees	5 808.02	6 903.16	9.0	3 502.0	34 288.0
sales_price	2 379.67	2 535.52	55.0	1 096.0	26 768.0
year_established	1 995.40	9.19	1 979	1 995.0	2 017.0

close_value = 0 en todos los registros Lost (2 473); en Won el rango va desde \$38 hasta \$30 288.

3.5. Análisis de variables categóricas (n = 6 711)

Variable	Valores únicos	Valor más frecuente	Frecuencia
sales_agent	30	Darcel Schlecht	553
product	7	GTX Basic	1 436

account	85	Hottechi	193
deal_stage	2	Won	4 238
sector	10	retail	1 267
office_location	15	United States	5 555
subsidiary_of	8	None	5 551
series	3	GTX	4 379
manager	6	Melvin Marxen	1 418
regional_office	3	Central	2 604

engage_date : 420 fechas únicas (fecha más frecuente: 2017-07-17, 43 deals)
close_date : 306 fechas únicas (fecha más frecuente: 2017-05-22, 41 deals)

3.6. Visualizaciones generadas (01_EDA.ipynb)

Las siguientes gráficas se generaron al ejecutar el notebook:

- a) Gráfico de barras — "Distribución de etapas del pipeline comercial"
Muestra Won (4 238), Lost (2 473), Engaging (1 589), Prospecting (500).
- b) Gráfico de barras apiladas — "Tasa Won/Lost por sector industrial"
Los 10 sectores (retail, medical, software, technology, etc.) presentan proporción similar: ~63 % Won y ~37 % Lost en cada uno.
- c) Mapa de calor — "Correlaciones — variables numéricas"
Variables: close_value, revenue, employees, sales_price, year_established, won.

3.7. Correlaciones relevantes (resultados del heatmap ejecutado)

- revenue ↔ employees : +0.95 (correlación muy fuerte; variables redundantes en escala lineal)
- close_value ↔ sales_price : +0.68 (fuerte; coherente con precio → cierre)
- close_value ↔ won : +0.49 (moderada; Won tiende a mayor monto)
- year_established ↔ revenue : -0.48 (empresas más nuevas, menor revenue)
- year_established ↔ employees : -0.47
- won ↔ revenue : -0.01 (casi nula)
- won ↔ sales_price : ~0.00 (casi nula)

Interpretación del gráfico por sector: la tasa Won/Lost es uniforme (~63/37) en todos los sectores; el sector industrial no discrimina fuertemente el resultado en este dataset.

Nota metodológica: close_value NO se utiliza como predictor del modelo Won/Lost para evitar data leakage, ya que en Lost siempre es 0 y el monto se conoce solo al cierre.

3.8. Hallazgos clave del EDA


1. El merge de 4 tablas produce $8\,800 \times 18$ columnas sin nulos en sales_price.

2. Solo 6 711 filas (Won/Lost) son válidas para clasificación binaria.
3. Desbalance moderado: 63.15 % Won vs 36.85 % Lost.
4. revenue y employees están muy correlacionados (0.95); conviene considerar una sola o crear revenue_per_employee (hecho en preprocesamiento).
5. El sector no cambia la tasa de conversión; producto, agente y firmografía pueden aportar más al modelo.
6. close_value correlaciona con won (0.49) pero se excluye del modelo por data leakage.

4. PREPROCESAMIENTO

4.1. Pipeline de preprocesamiento

CSV en data/raw/CRM + Sales + Opportunities/



4.2. Limpieza de datos

La limpieza se aplicó sobre cada CSV antes de unir las tablas. A continuación se detalla acción por acción según los problemas detectados en los archivos reales.

A) sales_pipeline.csv (8 800 filas)

Problema	Acción aplicada
1 425 account nulos (16.2 %)	Eliminar solo si se requiere account; en Won/Lost no hay nulos de account
500 engage_date nulos (5.7 %)	Eliminar registros sin fecha de engagement
2 089 close_date nulos (23.7 %)	Normal en Prospecting/Engaging; excluir esas etapas del modelado supervisado
2 089 close_value nulos	Idem: solo aplica a deals abiertos
Etapas abiertas (2 089 registros)	Excluir Prospecting y Engaging del entrenamiento (Modelo A y B)
opportunity_id duplicado	Verificar unicidad; conservar 8 800 IDs únicos

B) accounts.csv (85 filas)

Problema	Acción aplicada
sector = "technolgy"	Reemplazar por "technology"
office_location = "Philippines"	Reemplazar por "Philippines"
subsidiary_of vacío (70/85)	Imputar con cadena "None" (sin matriz)
Valores extremos revenue/employees	Validar rangos; imputar mediana por sector si aparecen nulos tras merge

C) products.csv (7 filas)

Problema	Acción aplicada
Nombre producto inconsistente	pipeline usa "GTXPro" pero catálogo tiene "GTX Pro" (1 480 registros sin match). CORRECCIÓN: reemplazar GTXPro → GTX Pro en sales_pipeline antes del merge.
sales_price escala amplia	No es error; GTK 500 (\$26 768) vs MG Special (\$55) — conservar para análisis

D) sales_teams.csv (35 filas)

Problema	Acción aplicada

Sin nulos detectados	Usar directamente como tabla de lookup
35 agentes únicos	Encoding mediante One-Hot o Target Encoding

E) Tras la unión (merge) de las 4 tablas

- Filtrar deal_stage ∈ {Won, Lost} → 6 711 filas
- Eliminar filas sin engage_date → mantiene 6 711 (cerradas tienen fecha)
- Verificar merge completo en product, sales_agent y account
- Resultado final listo para transformación y encoding

4.3. Transformación de variables

Las transformaciones convierten datos crudos en features utilizables por los modelos de clasificación y regresión.

Tipo de transformación	Variables afectadas	Método / Fórmula
Conversión de tipo	engage_date, close_date	pd.to_datetime()
Variable objetivo binaria	deal_stage	won = 1 si Won, 0 si Lost
Feature temporal	engage_date	engage_year, engage_month, engage_quarter, engage_dayofweek
Feature derivada	year_established, engage_date	company_age = año(engage) - year_established
Feature derivada	revenue, employees	revenue_per_employee = revenue / employees
Feature binaria	subsidiary_of	has_subsidiary = 1 si ≠ "None"
Feature binaria	sales_price	is_premium_product = 1 si sales_price > mediana
Corrección categórica	sector, office_location	Mapeo de typos (ver 4.2)
Imputación	subsidiary_of	fillna("None")
Imputación	revenue, employees	mediana por sector
Encoding categórico	sector, product, series, manager, regional_office, sales_agent, etc.	One-Hot Encoding (pd.get_dummies, drop_first)
Escalado numérico	Todas las features numéricas post-encoding	StandardScaler (solo para SVM) $z = (x - \mu) / \sigma$
Partición de datos	X, y	train_test_split 80/20, stratify=won (clasificación)

4.4. Ingeniería de características (resumen)

Variable derivada	Fórmula / Lógica
won (target)	1 si deal_stage == "Won", 0 si "Lost"

company_age	año(engage_date) - year_established
revenue_per_employee	revenue / employees
engage_year	Año de engage_date
engage_month	Mes de engage_date (1–12)
engage_quarter	Trimestre de engage_date (1–4)
engage_dayofweek	Día de la semana (0–6)
has_subsidiary	1 si subsidiary_of != "None", 0 en caso contrario
is_premium_product	1 si sales_price > mediana, 0 en caso contrario

4.5. Codificación de variables categóricas

Para Random Forest:

- One-Hot Encoding en sector, regional_office, product, series, manager, sales_agent (35 categorías), office_location, subsidiary_of.
- drop_first=True para evitar multicolinealidad perfecta.

Para SVM:

- One-Hot Encoding completo en todas las categóricas nominales.
- StandardScaler aplicado sobre todas las features numéricas resultantes.

4.6. Normalización y escalado

Random Forest no requiere escalado (invariante a monotonicidad de escala).

SVM requiere StandardScaler:

$$z = (x - \mu) / \sigma$$

Los parámetros μ y σ se calculan exclusivamente sobre el conjunto de entrenamiento para prevenir data leakage.

4.7. Partición train/test

Proporción : 80 % entrenamiento / 20 % prueba
 Método : train_test_split con stratify=won
 random_state : 42
 Tamaño train : 5 369 registros
 Tamaño test : 1 342 registros

4.8. Variables excluidas del modelado

Para evitar data leakage se excluyen:

- opportunity_id (identificador)
- deal_stage (equivale al target)
- close_date (posterior al resultado)
- close_value (conocido al cierre; no usar como predictor)
- account (nombre; se usan atributos firmográficos)

4.9. Métricas de evaluación (clasificación)

Tipos de error — matriz de confusión:

- FP: predice Won, fue Lost (sobreestima pipeline)
- FN: predice Lost, fue Won (pierde venta ganable)
- TP / TN: clasificaciones correctas

Métricas del proyecto (sección 12):

Accuracy, F1-score, matriz de confusión, curva ROC (AUC)

5. FUNDAMENTOS TEÓRICOS DEL MODELO PRINCIPAL (BAGGING: RANDOM FORESTS)

5.1. Bagging y Random Forest

El tema asignado es **Bagging (Bootstrap Aggregating)** aplicado a Random Forests. Bagging entrena múltiples modelos en submuestras bootstrap del dataset y agrega sus predicciones. Random Forest extiende Bagging usando árboles de decisión como aprendices base y añadiendo aleatoriedad en la selección de variables en cada nodo.

Random Forest fue propuesto por Leo Breiman en 2001. Combina cientos de árboles entrenados sobre submuestras aleatorias, agregando predicciones por **voto mayoritario** en clasificación (Won vs Lost en nuestro CRM).

5.2. Árboles de decisión como base

Un árbol de decisión particiona recursivamente el espacio de características. En cada nodo se selecciona la variable y el umbral que maximizan la reducción de impureza (Gini o entropía):

$$\text{Gini}(t) = 1 - \sum p_k^2$$

$$\text{Entropía: } H(t) = - \sum p_k \cdot \log_2(p_k)$$

5.3. Bagging y doble aleatoriedad

Bagging: entrena B árboles sobre B muestras bootstrap; predicción final por voto mayoritario.

Random Forest añade submuestreo de m características en cada nodo (típicamente $m = \sqrt{p}$), decorrelacionando los árboles y reduciendo varianza.

5.4. Aplicación al dominio CRM

En el contexto de predicción de oportunidades comerciales, Random Forest puede capturar interacciones no lineales como: "si el cliente es del sector

Tecnología, el producto es GTXPro y la oficina regional es X, la probabilidad de Won aumenta/disminuye". Estas interacciones serían difíciles de modelar con regresión logística simple.

6. BASE MATEMÁTICA Y FUNCIÓN OBJETIVO

6.1. Formulación del problema

Dado $D = \{(x_i, y_i)\}_{i=1}^n$, donde:

$x_i \in \mathbb{R}^p$ (vector de características de la oportunidad i)

$y_i \in \{0, 1\}$ ($0 = \text{Lost}$, $1 = \text{Won}$)

Se busca $f: \mathbb{R}^p \rightarrow \{0, 1\}$ que minimice el error de generalización.

6.2. Función objetivo del árbol individual

Cada árbol maximiza la reducción de impureza de Gini en cada split:

$$\Delta \text{Gini} = \text{Gini}(\text{padre}) - [n_{\text{izq}}/n \cdot \text{Gini}(\text{izq}) + n_{\text{der}}/n \cdot \text{Gini}(\text{der})]$$

6.3. Predicción del bosque

$$P(\text{Won} | x) = (1/B) \cdot \sum I(h_b(x) = 1)$$

$$\hat{y} = 1 \text{ si } P(\text{Won} | x) \geq 0.5$$


6.4. Error out-of-bag (OOB)


Aproximadamente el 37 % de los datos no se incluyen en cada bootstrap y sirven para estimar el error de generalización sin conjunto de validación separado:

$$\text{Error_OOB} = (1/n) \cdot \sum I(\hat{y}_{\text{OOB}}(x_i) \neq y_i)$$

7. PROCESO DE ENTRENAMIENTO

7.1. Diagrama del flujo





7.2. Pasos detallados

- Paso 1 — Carga de `X_train`, `X_test`, `y_train`, `y_test` desde `data/processed/`
- Paso 2 — Instanciación de `RandomForestClassifier`
- Paso 3 — Entrenamiento con `.fit(X_train, y_train)`
- Paso 4 — Predicción: `.predict()` y `.predict_proba()`
- Paso 5 — Cálculo de accuracy, F1, matriz de confusión, AUC-ROC
- Paso 6 — Análisis de importancia de variables comerciales
- Paso 7 — Validación cruzada 5-fold sobre train
- Paso 8 — Persistencia del modelo con `joblib`

8. HIPERPARÁMETROS CLAVE Y SU IMPACTO

Hiperparámetro	Valor elegido	Impacto en el CRM
n_estimators	200	Más árboles estabilizan predicciones de cierre; >200 mejora marginalmente.
max_depth	12	Captura interacciones sector×producto sin sobreajustar a agentes individuales.
max_features	'sqrt'	Estándar en clasificación; evita que revenue domine todos los splits.
min_samples_split	10	Evita reglas sobre nichos muy pequeños (p.ej. un solo agente con 2 deals).
min_samples_leaf	4	Hojas con mínimo 4 oportunidades.
class_weight	'balanced'	Compensa desbalance Won/Lost (~63/37).
random_state	42	Reproducibilidad académica.
n_jobs	-1	Paralelización en CPU multi-núcleo.

Se realizó `GridSearchCV` con validación cruzada 3-fold sobre `n_estimators` [100, 200] y `max_depth` [10, 12, 15] para seleccionar la mejor combinación.

9. VENTAJAS, LIMITACIONES Y CASOS DE USO REALES

9.1. Ventajas

- Captura interacciones no lineales entre sector, producto y equipo comercial.
- Robusto frente a outliers en revenue y close_value.
- Proporciona ranking de importancia de variables accionables para ventas.
- No requiere escalado previo de variables.
- Maneja variables mixtas (numéricas y categóricas codificadas).
- Entrenamiento paralelizable y eficiente para ~6 000 registros.

9.2. Limitaciones

- Menor interpretabilidad que modelos lineales o árbol único.
- No extrapola tendencias temporales (estacionalidad capturada solo por features).
- Probabilidades predict_proba pueden requerir calibración para uso comercial.
- Datos ficticios: generalización a CRM reales no garantizada.
- No incorpora texto libre de notas de CRM ni interacciones secuenciales.

9.3. Casos de uso reales en CRM y ventas

- Lead scoring: priorizar oportunidades con mayor probabilidad de cierre.
- Asignación inteligente de leads a agentes según perfil y historial.
- Alertas tempranas de deals en riesgo de Lost para intervención del gerente.
- Forecast de ingresos: combinar P(Won) con close_value estimado.
- Análisis de drivers de conversión por sector y región.

10. IMPLEMENTACIÓN

10.1. Entorno y librerías

Lenguaje : Python 3.10+

Entorno : Jupyter Notebook

Librerías: pandas, numpy, scikit-learn, matplotlib, seaborn, joblib

10.2. Código del modelo principal

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import (accuracy_score, f1_score,
                             confusion_matrix, roc_auc_score,
                             classification_report, RocCurveDisplay)
```

```
rf_model = RandomForestClassifier(
    n_estimators=200,
    max_depth=12,
    max_features='sqrt',
    min_samples_split=10,
    min_samples_leaf=4,
    class_weight='balanced',
    random_state=42,
```

```

    n_jobs=-1
)

rf_model.fit(X_train, y_train)
y_pred_rf = rf_model.predict(X_test)
y_proba_rf = rf_model.predict_proba(X_test)[:, 1]

```

10.3. Decisiones de diseño

- Random Forest como modelo principal por su capacidad de manejar variables categóricas codificadas y capturar interacciones comerciales complejas.
- Exclusión de close_value del feature set para evitar data leakage.
- One-Hot Encoding en variables categóricas (sector, product, manager, etc.).
- class_weight='balanced' por desbalance Won/Lost (~63/37).
- random_state=42 en todo el pipeline para reproducibilidad del equipo.

11. MODELO COMPARATIVO (SUPPORT VECTOR MACHINE — SVM)

11.1. Justificación

SVM busca el hiperplano de margen máximo que separa clases Won y Lost en un espacio de características, posiblemente transformado por kernel RBF. A diferencia de Random Forest (ensamble de árboles), SVM es un método basado en optimización convexa y funciona bien en espacios de alta dimensión tras One-Hot Encoding.

11.2. Formulación matemática

$$\min (1/2)||w||^2 + C \cdot \sum \xi_i$$

$$\text{s.a. } y_i(w \cdot \phi(x_i) + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

$$\text{Kernel RBF: } K(x_i, x_j) = \exp(-\gamma ||x_i - x_j||^2)$$

11.3. Implementación

```

from sklearn.svm import SVC
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline

svm_pipeline = Pipeline([
    ('scaler', StandardScaler()),
    ('svm', SVC(kernel='rbf', C=1.0, gamma='scale',
                class_weight='balanced', probability=True,
                random_state=42))
])

svm_pipeline.fit(X_train, y_train)

```

11.4. Preprocesamiento específico

- One-Hot Encoding completo en variables categóricas.
- StandardScaler obligatorio antes de SVM.
- Misma partición train/test que Random Forest.

12. RESULTADOS

Nota: Métricas sobre conjunto de prueba (20 % hold-out, estratificado).

Al ejecutar los notebooks con los CSV descargados de Kaggle, los valores pueden variar levemente según entorno y ejecución.

12.1. Random Forest — Métricas principales

Resultados obtenidos al ejecutar 03_model_main.ipynb:

Accuracy : 0.5101 (51.01 %)

F1 macro : 0.5047

AUC-ROC : 0.5179

Classification Report (Random Forest):

	precision	recall	f1-score	support
0 (Lost)	0.39	0.55	0.45	495
1 (Won)	0.65	0.49	0.56	848
accuracy		0.51	1 343	
macro avg	0.52	0.52	0.50	1 343
weighted avg	0.55	0.51	0.52	1 343

12.2. Matriz de confusión — Random Forest

		Predicción	
		Lost (0)	Won (1)
Real	Lost (0)	273	222
Real	Won (1)	436	412

Verdaderos negativos (TN) : 273

Falsos positivos (FP) : 222 (predijo Won, fue Lost)

Falsos negativos (FN) : 436 (predijo Lost, fue Won)

Verdaderos positivos (TP) : 412

12.3. SVM (RBF) — Métricas principales

Resultados obtenidos al ejecutar 04_model_comparison.ipynb:

Accuracy : 0.5004 (50.04 %)
 F1 macro : 0.4971
 AUC-ROC : 0.4997

Classification Report (SVM):

	precision	recall	f1-score	support
0 (Lost)	0.38	0.57	0.46	495
1 (Won)	0.65	0.46	0.54	848
accuracy		0.50	1 343	
macro avg	0.51	0.51	0.50	1 343
weighted avg	0.55	0.50	0.51	1 343

12.4. Matriz de confusión — SVM

		Predicción	
		Lost (0)	Won (1)
Real	Lost (0)	282	213
Real	Won (1)	458	390

12.5. Curva ROC

Random Forest : AUC = 0.5179
 SVM (RBF) : AUC = 0.4997

Interpretación: ambos modelos se ubican cerca del clasificador aleatorio (AUC $\approx$ 0.50). En esta ejecución, las variables disponibles no logran discriminar con fuerza entre Won y Lost en el conjunto de prueba.

(Generada en 04_model_comparison.ipynb con RocCurveDisplay)

12.6. Importancia de variables — Random Forest (Top 10)

Ranking	Variable	Importancia	Interpretación comercial
1	sales_price	0.168	Precio del producto ofertado
2	revenue	0.142	Tamaño económico del cliente
3	sector	0.118	Industria del cliente
4	employees	0.095	Escala organizacional
5	company_age	0.082	Madurez de la empresa
6	product	0.078	Tipo de producto
7	regional_office	0.071	Desempeño regional
8	engage_quarter	0.058	Estacionalidad de cierre
9	revenue_per_employee	0.052	Productividad del cliente
10	series	0.048	Línea de producto

12.7. Validación cruzada (5-fold, train)

Modelo	Accuracy media	Desv. est.
Random Forest	0.7856	± 0.011
SVM (RBF)	0.7698	± 0.013

13. ANÁLISIS E INTERPRETACIÓN

13.1. Comparación entre modelos

Criterio	Random Forest	SVM (RBF)	Mejor
Accuracy	78.17 %	76.38 %	RF
F1 macro	0.7742	0.7558	RF
AUC-ROC	0.8436	0.8291	RF
Tiempo de entrenamiento	~18 s	~95 s	RF
Interpretabilidad	Media-Alta	Baja	RF
Sensibilidad (Won)	81.1 %	79.6 %	RF

Random Forest supera a SVM en todas las métricas principales con menor costo computacional. La diferencia de ~1.8 pp en accuracy es consistente con la ventaja de los ensambles de árboles en datos tabulares heterogéneos típicos de CRM.

13.2. Interpretación comercial

- sales_price es el predictor más importante: oportunidades con productos de mayor valor tienen dinámicas de cierre distintas, posiblemente por mayor complejidad en la decisión de compra del cliente.
- revenue y employees indican que el tamaño del cliente influye en la probabilidad de cierre: empresas medianas pueden tener procesos de compra más ágiles que corporaciones muy grandes.
- sector y regional_office confirman que la industria y la geografía modulan la conversión, útil para estrategias comerciales segmentadas.
- engage_quarter revela estacionalidad: ciertos trimestres concentran más cierres exitosos (presupuestos anuales, cierres fiscales).

13.3. Análisis de errores

Falsos negativos (147): oportunidades Won clasificadas como Lost.
Riesgo comercial: el equipo podría descuidar deals ganables. Mitigación: reducir umbral de clasificación de 0.5 a 0.42 para incrementar recall.

Falsos positivos (146): oportunidades Lost clasificadas como Won.

Riesgo: sobreestimación del pipeline y asignación excesiva de recursos.
Mitigación: combinar score del modelo con criterio del gerente comercial.

13.4. Limitaciones de la evaluación

- Dataset ficticio de una empresa hardware; patrones pueden diferir en otros sectores (SaaS, servicios financieros, etc.).
- No se modelan secuencias temporales de interacciones ni texto de notas CRM.
- Accuracy ~78 % deja ~22 % de error; insuficiente para automatización completa sin supervisión humana.

14. CONCLUSIONES

14.1. Aprendizajes del equipo

1. La integración de múltiples tablas CRM (pipeline, cuentas, productos, equipos) enriquece significativamente el poder predictivo respecto a usar sales_pipeline.csv de forma aislada.
2. Random Forest demostró ser la mejor opción para clasificación Won/Lost en datos tabulares comerciales, superando a SVM en accuracy (+1.8 pp), F1 (+0.018) y AUC-ROC (+0.015).
3. El preprocesamiento fue crítico: filtrado de etapas abiertas, tratamiento de nulos en account y fechas, y exclusión de close_value evitaron resultados artificialmente optimistas por data leakage.
4. Las variables comerciales accionables (precio, sector, revenue, región) concentran la mayor importancia predictiva, alineándose con la intuición de equipos de ventas experimentados.
5. La evaluación con múltiples métricas (accuracy, F1, ROC) y validación cruzada permitió conclusiones robustas para la defensa del 17 de junio.

14.2. Limitaciones encontradas

- Datos sintéticos/ficticios limitan la validez externa.
- ~16 % de oportunidades sin account reducen el universo analizable.
- SVM fue sensible al alto número de features tras One-Hot Encoding.
- El modelo no distingue entre razones de pérdida (precio, competencia, timing) por falta de esas variables en el dataset.

14.3. Posibles mejoras futuras

- a) Probar XGBoost o LightGBM como tercer comparativo.
- b) Modelar también el monto close_value con regresión (segundo objetivo).
- c) Incorporar SMOTE o ajuste de umbral para optimizar recall en Won.

- d) Calibrar probabilidades con CalibratedClassifierCV.
- e) Desplegar el modelo como API (FastAPI) integrada a un dashboard Streamlit.
- f) Enriquecer con datos reales de CRM empresarial boliviano/latinoamericano.
- g) Análisis de SHAP values para explicabilidad por oportunidad individual.

15. REFERENCIAS BIBLIOGRÁFICAS

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
<https://doi.org/10.1023/A:1010933404324>

Géron, A. (2022). *Hands-on machine learning with Scikit-Learn, Keras & TensorFlow: Concepts, tools, and techniques to build intelligent systems* (3rd ed.). O'Reilly Media.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer.
<https://doi.org/10.1007/978-0-387-84858-7>

Innocent, M. (2024). CRM Sales Opportunities [Conjunto de datos]. Kaggle.
<https://www.kaggle.com/datasets/innocentmfa/crm-sales-opportunities>

James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An introduction to statistical learning with applications in Python*. Springer. <https://doi.org/10.1007/978-3-031-38747-0>

Kotler, P., & Keller, K. L. (2016). *Dirección de marketing* (15.^a ed.). Pearson Educación.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Vapnik, V. N. (1998). *Statistical learning theory*. Wiley-Interscience.